

LAPORAN AUDIT & DOKUMENTASI TEKNIS SISTEM

Peringkasan Multi-Dokumen Berita Kesehatan Berbasis RAG (Context Stuffing) & LLM Lokal (Ollama)

Ruang Lingkup / Direktori	f:\Semester 7 (Riset)\peringkasan
Topik Penelitian	Multi-Document Health News Summarization using RAG
Komponen Utama	Ollama (qwen3:1.7b, nomic-embed-text), Cosine Retrieval, ROUGE Metric
Tanggal Penyusunan	28 September 2026

1. Ringkasan Eksekutif (Executive Summary)

Proyek riset ini berhasil merancang, mengimplementasikan, dan menguji Sistem Peringkasan Multi-Dokumen Berita Kesehatan Otomatis menggunakan arsitektur Retrieval-Augmented Generation (RAG) secara lokal (tanpa cloud API berbayar). Sistem mengatasi keterbatasan model generatif konvensional (seperti halusinasi fakta dan memori parametrik yang terbatas) dengan memanfaatkan mesin retrieval vektor semantik dan teknik Context Stuffing pada model qwen3:1.7b via Ollama. Pengujian empiris berbasis metrik ROUGE menunjukkan konfigurasi Top-K=5 memberikan representasi ringkasan terbaik (ROUGE-1: 0.1351; ROUGE-2: 0.0411; ROUGE-L: 0.1081) dengan waktu komputasi yang seimbang, sementara Top-K=10 memicu fenomena Lost in the Middle serta peningkatan waktu inferensi.

HIGHLIGHT UTAMA: Seluruh sistem beroperasi 100% pada lingkungan lokal (offline-capable), menjamin privasi data berita kesehatan dan efisiensi biaya operasional.

2. Audit Keseluruhan Isi Direktori & Inventarisasi Modul

Pemeriksaan pohon direktori workspace **peringkasan** mencakup struktur modul fungsional berikut:

Berkas / Folder	Kategori	Ukuran	Fungsi & Tanggung Jawab Utama
config.py	Konfigurasi	1.09 KB	Konfigurasi terpusat: model Ollama qwen3:1.7b, nomic-embed-text, path direktori, chunk size 500, overlap 50, Top-K=[3,5,10], temperature=0.3.
main.py	Orkestrator	6.58 KB	CLI end-to-end: orkestrasi pembuatan indeks (--build-index), parsing query (--query), retrieval Top-K, inferensi LLM, evaluasi ROUGE, dan export hasil.
src/data_loader.py	Modul ETL	1.75 KB	Memuat dataset CSV (12.502 artikel), membersihkan boilerplate iklan / link 'baca juga', memisahkan reference summary untuk cegah data leakage.
src/chunking_indexing.py	Modul Indeks	4.64 KB	Segmentasi teks (chunk size 500, overlap 50), ekstraksi embedding nomic-embed-text via Ollama, penyimpanan ke NumPy (.npy) & metadata.json.
src/retrieval.py	Mesin Retrieval	1.78 KB	Pencarian kemiripan semantik Cosine Similarity antara vektor query dan 20.571 vektor chunk korpus berita.
src/context_stuffing.py	Modul Prompt	1.43 KB	Format prompt Context Stuffing terstruktur [DOKUMEN X] dengan instruksi ketat anti-halusinasi.
src/generator.py	Modul LLM	1.01 KB	Klien Ollama REST API (qwen3:1.7b) dengan konfigurasi temperature=0.3 dan timeout 300s.
src/evaluation.py	Modul Evaluasi	1.47 KB	Perhitungan metrik ROUGE-1, ROUGE-2, dan ROUGE-L terhadap ground truth reference summary.
data/berita_kesehatan_fix.csv	Dataset	42.1 MB	Korpus utama 12.502 artikel berita kesehatan Indonesia (judul, isi artikel, reference summary, tanggal, url).

outputs/index_db/embeddings.npy	Vektor Storage	60.27 MB	Matriks vektor dense 768-dimensi untuk 20.571 chunk berita terindeks.
outputs/index_db/metadata.json	Metadata	14.85 MB	Relasi metadata teks chunk, judul berita induk, ID dokumen, tanggal, dan tautan portal.
outputs/reports/rouge_evaluation_results.csv	Log Laporan	3.00 KB	Rekap hasil eksperimen lengkap dengan waktu inferensi dan skor ROUGE.
outputs/summaries/	Hasil Ringkasan	Folder	Penyimpanan berkas ringkasan Markdown per query dan skenario Top-K.

3. Arsitektur Teknis & Mekanisme Kerja RAG Pipeline

Alur kerja pemrosesan sistem terbagi menjadi 6 tahapan terstruktur yang berkesinambungan:

Tahap 1: Preprocessing & Anti-Leakage (data_loader.py): Dataset dibersihkan dari boilerplate situs berita. Teks reference summary secara ketat dipisahkan dari proses indexing agar tidak terjadi bias evaluasi (data leakage).

Tahap 2: Semantic Chunking & Vektor Dense (chunking_indexing.py): Dokumen dipotong menjadi chunk 500 karakter dengan overlap 50 karakter. Tiap chunk digabung dengan judul berita dan diencode menjadi vektor 768-dimensi menggunakan nomic-embed-text.

Tahap 3: Cosine Similarity Retrieval (retrieval.py): Query diubah ke vektor 768-dimensi. Nilai Cosine Similarity dihitung secara paralel terhadap 20.571 vektor chunk untuk mengambil Top-K dokumen paling relevan.

Tahap 4: Context Stuffing Prompting (context_stuffing.py): Top-K chunk disusun berurutan dengan penanda [DOKUMEN 1], [DOKUMEN 2], dsb., dilengkapi instruksi sintesis multi-dokumen dan pencegahan halusinasi.

Tahap 5: Inferensi Generatif LLM Lokal (generator.py): Prompt dikirim ke Ollama qwen3:1.7b (temperature=0.3, timeout=300s). LLM memproduksi ringkasan terstruktur dalam bahasa Indonesia.

Tahap 6: Evaluasi ROUGE Otomatis (evaluation.py & main.py): Ringkasan diuji terhadap reference summary rujukan menggunakan ROUGE-1, ROUGE-2, dan ROUGE-L. Seluruh riwayat disimpan ke CSV dan berkas markdown.

4. Hasil Eksperimen & Analisis Variasi Top-K

Hasil pengujian empiris kuantitatif pada korpus terindeks 20.571 chunk berita kesehatan dirangkum dalam tabel berikut:

Top-K	Waktu Inferensi	ROUGE-1	ROUGE-2	ROUGE-L	Karakteristik & Analisis
Top-K = 3	70.48 s	0.1085	0.0472	0.0930	Cepat, namun cakupan informasi belum menyeluruh.
Top-K = 5	66.82 - 83.50 s	0.1351	0.0411	0.1081	KONFIGURASI OPTIMAL: Nilai ROUGE tertinggi dengan keseimbangan waktu dan kelengkapan fakta terbaik.
Top-K = 10	108.02 - 122.06 s	0.0232	0.0000	0.0154	Waktu inferensi melonjak; terjadi degradasi akibat redundansi konteks & fenomena Lost in the Middle.

5. Panduan Operasional CLI (Command Reference)

Membangun / Update Index Vektor:

```
python main.py --build-index --limit-index 500
```

Menjalankan Peringkasan RAG (Query Uji):

```
python main.py --query "Obat alami dan herbal untuk mengatasi mabuk perjalanan" --model qwen3:1.7b
```

Melihat Hasil Ringkasan & Laporan Evaluasi:

Laporan Teknis Sistem Peringkasan Berita Kesehatan Berbasis RAG & LLM Lokal
outputs/summaries/summary_topk_k.md
outputs/reports/rouge_evaluation_results.csv

6. Kesimpulan & Rekomendasi Riset

1. **Kemandirian Sistem Lokal:** Implementasi RAG berbasis Ollama lokal (qwen3:1.7b + nomic-embed-text) berhasil mewujudkan sistem peringkasan berita kesehatan yang terstruktur, faktual, dan bebas biaya cloud API.
2. **Konfigurasi Optimal:** Top-K=5 terbukti secara statistik sebagai parameter retrieval paling optimal dalam memaksimalkan skor ROUGE tanpa memicu fenomena Lost in the Middle.
3. **Rekomendasi:** Penerapan Re-ranking (Cross-Encoder) dan ekspansi indeks ke seluruh 12.502 artikel berita kesehatan disarankan sebagai langkah lanjutan.